



# DIPLOMADO ESTADÍSTICA APLICADA A LA TOMA DE DECISIONES

**SEGUNDA VERSIÓN** 

# **Laboratorio Spark Machine Learning**

NOMBRE: HEBERT JUAN DE DIOS DELGADILLO FERNANDEZ

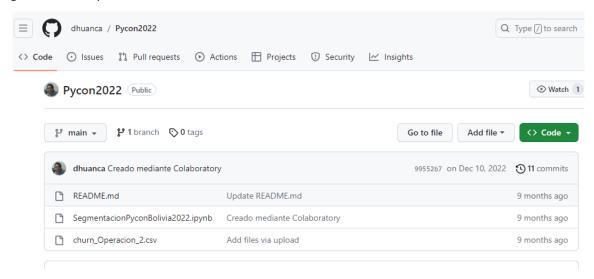
**CARLOS ALFREDO ORIHUELA BERRIOS** 

DOCENTE: DANNY LUIS HUANCA SEVILLA

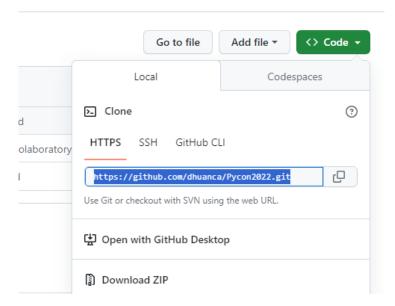
Cochabamba – Bolivia 2023 1. Clonar el siguiente repositorio en github. Pueden utilizar Colab, Databricks o la máquina virtual proporcionada. La dirección es la siguiente:

https://github.com/dhuanca/Pycon2022.git

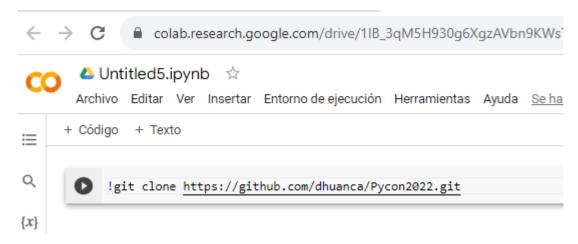
#### Ingresamos al repositorio GIT



#### copiamos el link para clonarlo en COLAB



Con el comando !git clone https://github.com/dhuanca/Pycon2022.git para clonar el repositorio de gitHub



Y al finalizar todos los archivos del repositorio están clonados en COLAB.



2. Ejecutar el laboratorio y obtener capturas de pantalla por cada ejecución generada

Instalamos la librería pyspark, para luego hacer uso SparkSession y trabajar con dataframe, en nuestro análisis de segmentación.

```
✓ Modelo Segmentación cliente
✓ Modelo Segmentación cliente
✓ Collecting pyspark
Downloading pyspark-3.4.1.tar.gz (310.8 MB)
— 310.8/310.8 MB 3.6 MB/s eta 0:00:00
Preparing metadata (setup.py) ... done
Requirement already satisfied: py4j==0.10.9.7 in /usr/local/lib/python3.10/dist-packages (from pyspark) (0.10.9.7)
Building wheels for collected packages: pyspark
Building wheel for pyspark (setup.py) ... done
Created wheel for pyspark: filename=pyspark-3.4.1-py2.py3-none-any.whl size=311285387 sha256=8e849c6e1eabb540a3c8979:
Stored in directory: /root/.cache/pip/wheels/0d/77/a3/ff2f74cc9ab41f8f594dabf0579c2a7c6de920d584206e0834
Successfully built pyspark
Installing collected packages: pyspark
Successfully installed pyspark-3.4.1
✓ from pyspark.sql import SparkSession import pandas as pd import matplotlib.pyplot as plt
```

#### El método builder es el constructor de instancias SparkSession

```
// (3] spark = SparkSession.builder.appName("Segmentacion").getOrCreate()
// (5)
// (6)
// (6)
// (7)
// (6)
// (7)
// (7)
// (8)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
// (9)
```

#### convertimos nuestro dataset en un dataframe de Spark.

```
9s [9] df_telco = spark.read.csv('drive/MyDrive/Pycon2022/churn_Operacion_2.csv', header=True, inferSchema=True)

y [10] df_telco.show(1)

| state | account | area_code | phone_number | international_plan | voice_mail_plan | number_vmail_messages | total_day_minutes | total_day_calls |
| KS | 128.0 | 415.0 | 382-4657 | no | yes | 25.0 | 265.1 | 110.0 |
| only showing top 1 row
```

#### Revisamos los metadatas del Dataframe

```
() [11] df_telco.printSchema()
        root
         -- state: string (nullable = true)
         -- account: double (nullable = true)
         |-- area code: double (nullable = true)
         |-- phone_number: string (nullable = true)
         -- international_plan: string (nullable = true)
         |-- voice_mail_plan: string (nullable = true)
         -- number_vmail_messages: double (nullable = true)
         -- total_day_minutes: double (nullable = true)
         -- total_day_calls: double (nullable = true)
         -- total_day_charge: double (nullable = true)
         -- total eve minutes: double (nullable = true)
         -- total_eve_calls: double (nullable = true)
         -- total_eve_charge: double (nullable = true)
         -- total_night_minutes: double (nullable = true)
         -- total_night_calls: double (nullable = true)
         |-- total_night_charge: double (nullable = true)
         -- total_intl_minutes: double (nullable = true)
         |-- total_intl_calls: double (nullable = true)
         -- total_intl_charge: double (nullable = true)
         |-- number_customer_service_calls: double (nullable = true)
         |-- churn.: string (nullable = true)
```

Definimos un schema para que el modelo identifique a las variables cuantitativas y cualitativas.

```
os [12] from pyspark.sql.types import StructType, StructField, StringType, LongType, IntegerType, DoubleType, FloatType

' [13] Mischema = StructType(
                StructField('state', StringType(), True),
                StructField('account', StringType(), True),
                StructField('area_code', StringType(), True),
                StructField('phone_number', StringType(), True),
                StructField('international_plan', StringType(), True),
                StructField('voice_mail_plan', StringType(), True),
                StructField("number_vmail_messages", DoubleType(), True),
                StructField('total_day_minutes', DoubleType(), True),
                StructField('total_day_calls', DoubleType(), True),
                StructField('total_day_charge', DoubleType(), True),
                StructField('total_eve_minutes', DoubleType(), True),
                StructField('total_eve_calls', DoubleType(), True),
                StructField('total_eve_charge', DoubleType(), True),
                StructField('total_night_minutes', DoubleType(), True),
                StructField('total_night_calls', DoubleType(), True),
                StructField('total_night_charge', DoubleType(), True),
                StructField('total_intl_minutes', DoubleType(), True),
                StructField('total_intl_calls', DoubleType(), True),
                StructField('total_intl_charge', DoubleType(), True),
                StructField('number_customer_service_calls', DoubleType(), True),
StructField('churn.', StringType(), True)
            1
```

Explorando los datos , por ejemplo: las 5 personas que menos reclamos y las 5 personas que más reclaman?

```
os df_telco.sort('number_customer_service_calls')[['number_customer_service_calls', 'phone_number']].show(5)
       +----+
       |number_customer_service_calls|phone_number|
                               0.0| 396-5800|
                                      395-2854
358-1958
                                0.0
                               0.0
                                0.0
                                      358-1921
                               0.0 343-4696
       only showing top 5 rows
v [18] from pyspark.sql import functions as F
(19] df_telco.sort(F.desc('number_customer_service_calls'))[['number_customer_service_calls', 'phone_number']].show
       |number_customer_service_calls|phone_number|
                              9.0 416-2778
                              9.0
                                     416-6886
                                    333-8822
                              8.0
                              8.0 371-1727
7.0 397-9184
      only showing top 5 rows
```

Para verificar el dominio de variables cualitativas se usan funciones de agrupación por ejemplo:

¿Cuál es la distribución por área?

```
[20] df_telco.groupBy(F.col('area_code')).count().show()

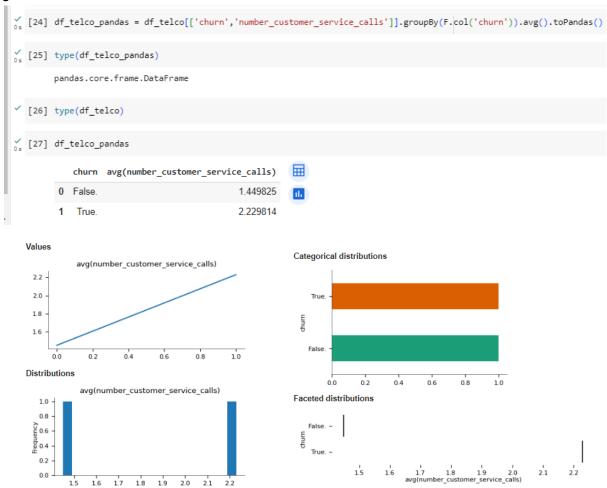
+-----+
| area_code|count|
+----+
| 408| 838|
| 510| 840|
| 415| 1655|
+-----+
```

¿Cuál es la distribución de la tenencia de un plan de llamadas internacionales?

# ¿Cuál es la media de mensajes de texto y llamadas al call center por estado?

```
// [22] df_telco[['state','number_vmail_messages','number_customer_service_calls']].groupBy(F.col('state')).avg().show()
       |state|avg(number_vmail_messages)|avg(number_customer_service_calls)|
       +----+
                               9.46875
           AZ
                                                               1.59375
                      8.683333333333334
                                                    1.58333333333333333
           SC
                      7.901960784313726
                                                     1.5686274509803921
                                                    1.5476190476190477
                      8.261904761904763
                     9.191176470588236
                                                     1.6764705882352942
           DC
                       9.74074074074074
                                                     1.3518518518518519
           OR
                       6.17948717948718
                                                     1.7307692307692308
           VA
                      7.038961038961039
                                                     1.5974025974025974
           RII
                      7.3230769230769231
                                                     1.4153846153846155
           WY
                       6.51948051948052
                                                     1.4415584415584415
                                                     1.7118644067796611
           KY
                                   7.0
                      8.267857142857142
                                                     1.5178571428571428
           NH |
                      8.452054794520548
           ΜI
                                                       1.63013698630137
                      6.80303030303030303
                                                     1.5909090909090908
                      8.282051282051283
                                                     1.4230769230769231
           WI
           ID
                     10.219178082191782
                                                     1.6712328767123288
           CA
                                   9.0
                                                     1.4705882352941178
           NE |
                      8.557377049180328
                                                      1,459016393442623
           CT
                      9.067567567567568
                                                     1.5135135135135136
           MT
                      9.338235294117647
                                                     1.6323529411764706
       only showing top 20 rows
```

Para graficar con Spark lo convertimos en dataframe de Pandas y usar laslibreria de graficación. usando el método **toPandas** 



#### Transformaciones para refinar datos

La variable churn. contiene un punto al final que podemos eliminarlo

```
df_telco.columns
['state',
      'account',
      'area_code',
      'phone_number',
      'international_plan',
     'voice mail plan',
     'number vmail messages',
     'total day minutes',
      'total_day_calls',
     'total_day_charge'
      'total_eve_minutes',
      'total_eve_calls',
      'total_eve_charge',
      'total_night_minutes',
      'total_night_calls',
      'total_night_charge',
     'total_intl_minutes',
     'total intl calls',
     'total intl charge',
      'number_customer_service_calls',
      'churn']
```

#### Eliminación de valores nulos

```
'
35 [32] df_telco_describe = df_telco.describe().toPandas()

√
0s [33] df_telco_describe
          summary state
                               account
                                                 area_code phone_number international_plan voice_mail_plan number_vmail_messages total_day_
                               3333
                                                                                  3333
                                                                                         3333
       0 count 3333
                                                     3333
                                                                 3333
                                                                                                                      3333
           mean None 101.06480648064806 437.18241824182417
                                                                                                           8.099009900990099 179.7750975
       2 stddev None 39.822105928595676 42.37129048560661
                                                                                                         13.688365372038598 54.4673892
                                                             None
                                                                                  None
                                                                                                 None
                                                              327-1058
             min
                                                                                    no
             max WY
                                                    510
                                                              422-9964
       5 rows × 22 columns
```

Borrar prosibles espacios vacios. Se usa la funcion trim

# Feature engineering

Se realiza una transformación de variables cualitativas.

Los modelos de ML no interpretan palabras o textos, estos deben ser convertidos a números.

Una de estas transformaciones es el one-hot-encoding

International_plan							
no							
yes							



international_plan_no	international_plan_yes				
1	0				
0	1				

```
v  [40] df_telco_final = final_df.select([
         'state',
         'area code',
         'international_plan',
         'voice_mail_plan',
         'number vmail messages',
         'total_day_minutes',
         'total_day_calls',
         'total day charge',
         'total eve minutes',
         'total_eve_calls',
         'total_eve_charge',
         'total night minutes',
         'total_night_calls',
         'total night charge',
         'total intl minutes',
         'total_intl_calls',
         'total_intl_charge',
         'number_customer_service_calls',
         "churn"])
```

#### Aplicando one hot encoding a international\_plan

```
'[42] international_plan_indexer = StringIndexer(inputCol='international_plan', outputCol= 'international_planIndex')

'[43] type(international_plan_indexer)

'[44] international_plan_encoder = OneHotEncoder(inputCol = 'international_planIndex', outputCol= 'international_planVec')

'[45] type(international_plan_encoder)

pyspark.ml.feature.OneHotEncoder
```

# Aplicando one hot encoding a area\_code

```
[48] area_code_indexer = StringIndexer(inputCol='area_code', outputCol= 'area_codeIndex')

[49] area_code_encoder = OneHotEncoder(inputCol = 'area_codeIndex', outputCol= 'area_codeVec')
```

#### Aplicando one hot encoding a voice\_mail\_plan

```
voice_mail_plan_indexer = StringIndexer(inputCol='voice_mail_plan', outputCol= 'voice_mail_planIndex')
voice_mail_plan_encoder = OneHotEncoder(inputCol = 'voice_mail_planIndex', outputCol= 'voice_mail_planVec')

[52] churn_indexer = StringIndexer(inputCol= 'churn', outputCol= 'churnIndex')

assembler = VectorAssembler(inputCols = [ 'area_codeVec', 'international_planVec', 'voice_mail_planVec',
                                              'number_vmail_messages',
                                               'total_day_minutes',
                                               'total_day_calls',
                                               'total_day_charge',
                                               'total_eve_minutes',
                                               'total_eve_calls',
                                               'total_eve_charge',
                                               'total_night_minutes',
                                               'total_night_calls',
                                               'total_night_charge',
                                               'total_intl_minutes',
                                               'total_intl_calls',
                                               'total_intl_charge',
                                               'number_customer_service_calls'
                                              ], outputCol= 'features')
```

Seleccionando las variables que se usarán en el análisis cluster

```
√
<sub>0s</sub> [54] df_telco_final.columns
         ['state',
          'area_code',
          'international_plan',
          'voice_mail_plan',
          'number_vmail_messages',
          'total_day_minutes',
          'total_day_calls',
          'total_day_charge',
          'total_eve_minutes',
          'total_eve_calls',
          'total_eve_charge',
          'total_night_minutes',
          'total_night_calls',
          'total_night_charge',
          'total_intl_minutes',
          'total_intl_calls',
          'total intl charge',
          'number_customer_service_calls',
          'churn']
```

Quitando la variable churn que sirve para un modelo de aprendizaje supervisado

```
df_telco_col_seg = df_telco_final.select([
# 'state',
 'area_code',
 'international_plan',
 'voice mail plan',
 'number vmail messages',
 'total_day_minutes',
 'total day calls',
 'total_day_charge',
 'total_eve_minutes',
 'total eve calls',
 'total eve charge',
 'total_night_minutes',
 'total_night_calls',
 'total_night_charge',
 'total_intl_minutes',
 'total_intl_calls',
 'total_intl_charge',
 'number_customer_service_calls'])
```

#### Modelado

Debido a que el problema de negocio tiene que ver con la identificación de grupos, se usará un algoritmo de clustering que se basa en distancias con la finalidad de crear grupos que se convertirán en segmentos.

Para ello importamos la librería del Modelo de Machine learning **KMeans** y su evaluador **ClusteringEvaluator** 

# dividimos los datos para el entrenamiento y el test 70% y 30% respectivamente

```
[60] train_data, test_data = df_telco_col_seg.randomSplit([0.7,0.3])

[61] fit_model = pipeline.fit(train_data)

[62] type(fit_model)
```

pyspark.ml.pipeline.PipelineModel

# Comenzamos con las clusterizaciones

only showing top 5 rows

	(4.0)						
54] predictions.sho	м(10)						
al_night_minutes	+	total_night_charge	total_intl_minutes	total_intl_calls	+  total_intl_charge	t  number_customer_se	ervice_calls
203.1	.  82.0	9.14	10.6	6.0	2.86	+ 	1.0
185.8	90.0	8.36	10.0	6.0	2.7	İ	0.0
203.0		9.14	12.1				1.0
223.5		10.06	10.1				3.0
111.2		5.0	12.1				2.0
236.0		10.62	13.8				2.0
230.8		10.39	9.5				6.6
192.2		8.65	9.8				3.6
210.5		9.47	7.5				2.0
98.6	109.0	4.44	8.9	4.0	2.4		1.0
•							
	rt(F.desc('voice_mai	l_plan')).show(5)					
[65] predictions.son							
[65] predictions.son	rt(F.desc('voice_mai 		_vmail_messages tot	al_day_minutes to	tal_day_calls tota	l_day_charge total	eve_minute:
[65] predictions.son		e_mail_plan number_		al_day_minutes to	tal_day_calls tota:	1_day_charge total_	eve_minute
[65] predictions.son	ernational_plan voic	e_mail_plan number_					152.
(65) predictions.son	ernational_plan voic	e_mail_plan number_	13.0	207.6	65.0	35.29	
[65] predictions.son   area_code inte   408    408	ernational_plan voic	e_mail_plan number_ yes  yes	13.0 19.0	207.6     155.7	65.0  104.0	35.29  26.47	152. 185.

# Otra forma de observar sería obteniendo una muestra y convertirlo en un dataframe Pandas

[66]	predict	ions_pandas = pred	lictions.sample(fr	action=0.5).toPand	las()							
, [67]	predict	ions_pandas.head(	1									
	ssages	total_day_minutes	total_day_calls	total_day_charge	total_eve_minutes	total_eve_calls	total_eve_charge	total	_intl_charge number_customer	_service_calls	area_codeIndex	international_planIndex
	0.0	17.6	121.0	2.99	161.7	125.0	13.74		2.86	1.0	2.0	0.0
	0.0	39.5	78.0	6.72	264.3	106.0	22.47		2.70	0.0	2.0	0.0
	0.0	51.9	108.0	8.82	162.0	83.0	13.77		2.73	3.0	2.0	0.0
	0.0	70.8	94.0	12.04	215.6	102.0	18.33	***	2.57	6.0	2.0	0.0
	0.0	74.5	117.0	12.87	200.8	98.0	17.07		2.85	3.0	2.0	0.0
	4											

```
'
[68] predictions.groupBy(F.col('prediction')).count().show()

       +----+
       |prediction|count|
       +----+
               1 182
               3 222
               4 | 161 |
               2 | 176 |
               0 209
(69) predictions_pandas['prediction'].value_counts()
           119
       0
           115
       1
           99
       2
           95
           77
       Name: prediction, dtype: int64
```

# Evaluando con el coeficiente de Silhouette

El coeficiente Silhouette se encuentra entre - 1 y 1 siendo lo mejor 1 y lo peor -1, el valor 0 indica que los clusters se están sobreponiendo.

```
[70] evaluador = ClusteringEvaluator()

[71] silhouette = evaluador.evaluate(predictions)
    print("El coeficiente Silhouette usando distancias euclidianas al cuadrado es = " + str(silhouette))

El coeficiente Silhouette usando distancias euclidianas al cuadrado es = 0.27846377025438307
```

3. En la última parte de clustering como vimos en clases identificar las características de cada grupo y asignar un nombre a cada grupo, por ejemplo un grupo podría ser: "las personas que tienen mayor cantidad de llamadas de día y también internacionales, por lo que se les puede ofrecer un paquete de datos en esos horarios y para cuando viajen"

#### teniendo los clustering

```
[74] predictions.groupBy(F.col('prediction')).count().show()

+-----+
| prediction|count|
+-----+
| 1| 182|
| 3| 222|
| 4| 161|
| 2| 176|
| 0| 209|
+-----+
```

luego agrupamos las variables, con la columna prediction

```
[78] predictions.columns
        ['area_code',
         'international_plan',
         'voice_mail_plan',
         'number_vmail_messages',
         'total_day_minutes',
         'total_day_calls',
         'total_day_charge'
         'total_eve_minutes',
         'total_eve_calls',
         'total_eve_charge',
         'total_night_minutes',
         'total_night_calls',
         'total_night_charge',
         'total_intl_minutes',
         'total_intl_calls',
         'total_intl_charge',
         'number_customer_service_calls',
         'area_codeIndex',
         'international_planIndex',
         'voice_mail_planIndex',
         'area_codeVec',
         'international_planVec',
         'voice_mail_planVec',
         'features',
         'prediction']
```

el grupo 0: es el grupo promedio

el grupo 1: personas que realizan más llamadas y recargas por las mañanas

el grupo 2: personas que realizan menos recargas por las mañanas y menos llamadas internacionales.

el grupo 3: personas que realizan más llamadas por las tardes y por las noches.

el grupo 4: personas que realizan más llamadas internacionales y menos llamadas por las noches.